

特征值与特征向量

1. 对方矩阵 A , 如果有 $A\mathbf{v} = \lambda\mathbf{v}$, 则称 λ 是方阵 A 的特征值, \mathbf{v} 是方阵 A 的特征向量。

特征向量和特征值的几何意义:

- 1) 方向不变: 线性变换 (矩阵 A 表示) 作用在特征向量, 不改变向量的方向
 - 2) 缩放: 线性变换 (矩阵 A 表示) 作用在特征向量只是对该向量的缩放
2. 特征分解: 将矩阵分解为一组特征值和特征向量的乘积, 只有可以对角化的矩阵才能进行特征分解。将特征向量组成矩阵 $V = (\mathbf{v}_1, \dots, \mathbf{v}_n)$, 将所有特征值组成对应特征向量的对角矩阵 $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$, 则

$$\mathbf{A} = \mathbf{V}\Lambda\mathbf{V}^{-1}$$

3. 杂

- 1) 特征值都大于 0, 称为正定矩阵
- 2) 特征值都大于等于 0, 称为半正定矩阵

对称矩阵

对称矩阵 A 满足 $A^T = A$, 每个元素都为实数的矩阵称为实对称矩阵:

- 1) 任意 \mathbf{A} 是实对称矩阵, 一定可以特征分解为

$$\mathbf{A} = \mathbf{Q}\Lambda\mathbf{Q}^T$$

其中 \mathbf{Q} 是正交矩阵, 由矩阵 \mathbf{A} 的特征向量组成 $\{\mathbf{v}_i\}_{i=1}^N$

- 2) 实对称矩阵的所有特征值都是实数

矩阵转置性质

基本性质:

$$(\mathbf{A}^T)^T = \mathbf{A} \quad (1)$$

$$(\mathbf{A} + \mathbf{B})^T = \mathbf{A}^T + \mathbf{B}^T \quad (2)$$

$$(c\mathbf{A})^T = c\mathbf{A}^T \quad (3)$$

$$(\mathbf{AB})^T = \mathbf{B}^T\mathbf{A}^T \quad (4)$$

$$\det(\mathbf{A}^T) = \det(\mathbf{A}) \quad (5)$$

$$\text{tr}(\mathbf{A}^T) = \text{tr}(\mathbf{A}) \quad (6)$$

$$\text{eigenValue}(\mathbf{A}) = \text{eigenValue}(\mathbf{A}^T) \quad (7)$$

反对称矩阵 (Skew-symmetric matrix) \mathbf{A} :

$$\mathbf{A}^T = -\mathbf{A} \quad (8)$$

矩阵的逆的性质

$$\mathbf{AA}^{-1} = \mathbf{I} \quad (9)$$

$$(\mathbf{AB})^{-1} = (\mathbf{BA})^{-1} \quad (10)$$

$$(\mathbf{A}^T)^{-1} = (\mathbf{A}^{-1})^T, \text{当矩阵 } \mathbf{A} \text{ 可逆} \quad (11)$$

正交矩阵

满足 $\mathbf{Q}^T\mathbf{Q} = \mathbf{I}$ 的矩阵 \mathbf{Q} 称为正交矩阵。正交矩阵性质:

$$\mathbf{Q}^T = \mathbf{Q}^{-1} \quad (12)$$

$$\det(\mathbf{Q}) = +1 \text{ 或 } -1 \quad (13)$$

$$\|\mathbf{Q}\mathbf{v}\| = \|\mathbf{v}\|, \text{正交矩阵不改变向量长度} \quad (14)$$

- 1) 正交矩阵保持向量的夹角不变, 旋转矩阵就是正交矩阵!
- 2) 正交矩阵的乘积依然是正交矩阵
- 3) 列向量和行向量都是正交的单位向量

相似矩阵

n 阶方矩阵 \mathbf{A} 和 \mathbf{B} 被称为相似 (记作 $\mathbf{A} \sim \mathbf{B}$), 如果存在一个可逆矩阵 \mathbf{P} , 使得 $\mathbf{B} = \mathbf{P}^{-1}\mathbf{A}\mathbf{P}$, 被称为相似变换。

几何意义: \mathbf{A} 和 \mathbf{B} 表示的是同一个线性变换, 但是相对于不同的基。

相似矩阵 \mathbf{A} 和 \mathbf{B} 矩阵具有相同的特征值, 但是并不一定有相同的特征向量。

$$\text{eigenValue}(\mathbf{A}) = \text{eigenValue}(\mathbf{B}) \quad (15)$$

$$\det(\mathbf{A}) = \det(\mathbf{B}) \quad (16)$$

$$\text{tr}(\mathbf{A}) = \text{tr}(\mathbf{B}) \quad (17)$$

$$\text{rank}(\mathbf{A}) = \text{rank}(\mathbf{B}) \quad (18)$$

$$\mathbf{A} \sim \mathbf{B}, \mathbf{B} \sim \mathbf{C} \rightarrow \mathbf{A} \sim \mathbf{C} \quad (19)$$

线性变换 Linear Map

线性变换 $T: V \rightarrow W$ 满足以下两个条件:

- 1) 对所有的 $u, v \in V$, 有 $T(u+v) = T(u) + T(v)$
- 2) 对所有的 $v \in V$ 和所有的标量 c , 有 $T(cv) = cT(v)$

即线性变换满足加法和标量乘法。除法呢?

透视投影矩阵涉及到除法操作 (求像素齐次坐标时包含除法) 不是一个线性变换! 可以通过上面的线性变换的性质, 例如加法性质自行证明。

奇异性 Singular

奇异性在数学中是指某种性质或状态异常或特殊。奇异矩阵会在线性变换时减少一个维度使得变换不可逆了, 这很“异常”。

- 奇异矩阵是行列式为 0 的矩阵, 奇异矩阵是不可逆矩阵, 奇异矩阵的行或列线性相关, 奇异矩阵至少有一个特征值为 0
- 奇异值分解 (Singular Value Decomposition, SVD) 对于一个 $m \times n$ 的矩阵 \mathbf{A} , 奇异值分解可以表示为:

$$\mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^T$$

Σ 对角矩阵上的值称为奇异值。

对角矩阵 Diag

对角矩阵 (D): 除了对角线都为 0 的方阵, 记作 $D = \text{diag}(d_1, d_2, \dots, d_n)$ 。对角矩阵有很多优良的性质, 计算上非常便利:

$$D^{-1} = \text{diag}\left(\frac{1}{d_1}, \frac{1}{d_2}, \dots, \frac{1}{d_n}\right) \quad (20)$$

$$\det(D) = d_1 \cdot d_2 \cdot \dots \cdot d_n \quad (21)$$

$$\text{tr}(D) = d_1 + d_2 + \dots + d_n \quad (22)$$

$$D^k = \text{diag}(d_1^k, d_2^k, \dots, d_n^k) \quad (23)$$

$$D_k \cdot D_m = \text{diag}(d_{k1}d_{m1}, d_{k2}d_{m2}, \dots, d_{kn}d_{mn}) \quad (24)$$

$$D_k + D_m = \text{diag}(d_{k1} + d_{m1}, d_{k2} + d_{m2}, \dots, d_{kn} + d_{mn}) \quad (25)$$

矩阵的相似对角化: 一个矩阵 A 与某个对角矩阵 Λ 相似, 即存在可逆矩阵 P , 使得

$$\Lambda = P^{-1}AP$$

则称矩阵 A 可以相似对角化, 称 Λ 为 A 的对角化形式, P 为对角化矩阵 (或特征向量矩阵)。对角化矩阵的主对角线元素的值全部为 A 的特征值。
相似对角化的条件: **并不是所有矩阵都可以相似对角化**, 条件是:

- 1) 矩阵 $A \in \mathbb{R}^{n \times n}$ 有 n 个线性无关的特征向量
- 2) 特征值的代数重数等于其几何重数: 1) 代数重数是特征值在特征多项式中出现的次数, 2) 几何重数是特征值对应的线性无关特征向量的个数 (即特征空间的维数)

KL Divergence

KL 散度用来度量两个分布之间的距离, **不符合交换律, 即交换两个分布后的距离不相等**

$$D_{KL}(P_\theta(x) \| Q_\phi(x)) = \sum_{x \in X} P_\theta(x) \cdot \log\left(\frac{P_\theta(x)}{Q_\phi(x)}\right) \quad (26)$$

Bayes' Theorem

贝叶斯定理理解: 给定相关的证据来更新我们对某一个假设的信念 (先验)。

$$P(H|E) = \frac{P(E|H) \cdot P(H)}{P(E)} \quad (27)$$

上面公式中, H 是我们的假设, E 是我们的证据 (数据), $P(H)$ 是我们对假设的信念, 比如说是对假设的先天的看法, 我们带着假设采集了很多新的证据 ($P(E|H)$), 由此更新了我们新的认知。 $P(H)$ 称为先验, $P(H|E)$ 称为后验, $P(E|H)$ 称为似然。

联合概率、条件概率、边缘概率

联合概率: $p(x, y)$ for $p(X = x, Y = y)$

条件概率 (X conditioned on Y): $p(x|y) = \frac{p(x, y)}{p(y)}$

边缘概率: $p(y_i) = \sum_{x \in X} p(x, y_i)$